



Tecnológico de Monterrey

Tecnológico de Monterrey, Estado de México

Inteligencia Artificial Avanzada para la ciencia de datos

Fecha de entrega: 09/09/2026

M2: momento de retroalimentación

Uso de framework o biblioteca de aprendizaje máquina para la implementación de una solución.

A01751729- Andrés Méndez Cortez

Profesor: Jorge Adolfo Ramírez Uresti

Descripción del Algoritmo Random Forest Classifier

El algoritmo implementado corresponde a un **Random Forest Classifier** (Bosque Aleatorio), el cual constituye un método de ensamble robusto para tareas de clasificación supervisada.

- **Construcción de ensambles:** Genera múltiples árboles de decisión individuales durante la fase de entrenamiento a partir de subconjuntos aleatorios de datos y variables.
- **Agregación de predicciones:** Combina las predicciones individuales de cada árbol para determinar el resultado final mediante votación mayoritaria, mejorando la estabilidad del clasificador.
- **Optimización y Pipeline:** Se integró dentro de un *Pipeline* estructurado para evitar la fuga de datos (data leakage) y se empleó *GridSearchCV* para automatizar la sintonización de hiperparámetros clave (profundidad máxima, número de estimadores y criterios de división).

Conjunto de Datos (Dataset)

El modelo fue entrenado y validado utilizando el archivo `dataset_compra_coche.csv`. Con el objetivo de garantizar una evaluación metodológica rigurosa y libre de sesgo, la partición de datos se realizó de forma estratificada:

- **Conjunto de Entrenamiento (Train - 80%):** Destinado al aprendizaje de patrones subyacentes y a la exploración de hiper parámetros mediante validación cruzada en Grid Search.
- **Conjunto de Prueba (Test - 20%):** Muestra aislada con datos nunca antes vistos por el estimador, garantizando que las métricas finales reflejen el desempeño en un entorno de inferencia real.

Métricas de Desempeño y Justificación

El proceso de optimización del algoritmo priorizó la métrica **F1-Score**, buscando balancear la precisión y la exhaustividad ante un posible desbalance entre clases. Evaluando el modelo final sobre el conjunto de prueba, se registraron las siguientes métricas:

Métrica	Valor	Interpretación
F1-Score	0.9310	Equilibrio sobresaliente entre precisión y exhaustividad; ratifica la confiabilidad global del clasificador (métrica de optimización elegida).
Accuracy	0.9000	El modelo determinó con acierto en el 90% de los casos totales si el cliente concretaría o no la compra.
Recall	1.0000	Desempeño perfecto (100%). Logró capturar la totalidad de los compradores reales sin incurrir en pérdidas de oportunidades comerciales.
Precision	0.8710	Del universo catalogado predictivamente como compradores, el 87.10% efectivamente formalizó la transacción.
Specificity	0.6923	Identificó de manera correcta al 69.23% de los prospectos no interesados en realizar la adquisición. Esta métrica está sesgada debido a la poca cantidad de registros negativos, por lo que se equivoca pocas veces pero cuentan demasiado cuando hay pocos registros.




Fig 2.1 Matriz de confusión del árbol de decisión categórico generado.

Análisis y Conclusión

El rendimiento obtenido evidencia una alta eficacia operativa en el modelo predictivo. La arquitectura basada en Random Forest resuelve inherentemente la tendencia al sobreajuste (*overfitting*) característica de los árboles individuales. Mientras un árbol aislado memoriza ruido específico del conjunto de entrenamiento, el ensamble mediante *bagging* (muestreo con reemplazo) y selección aleatoria de variables promedia las estimaciones, reduciendo la varianza y logrando una mayor capacidad de generalización frente a registros inéditos.

En términos de la matriz de confusión, el modelo alcanzó **27 Verdaderos Positivos (VP)** y **0 Falsos Negativos (FN)**, sustentando el *Recall* perfecto de 1.0000: la empresa no deja escapar ningún cliente dispuesto a comprar. El margen de optimización se concentra en los **4 Falsos Positivos (FP)** (clientes proyectados como compradores que finalmente no adquirieron la unidad), dando lugar a la especificidad de 0.6923.

La configuración actual resulta sumamente conveniente para un entorno comercial donde el costo de perder una venta es sustancialmente mayor al costo de contactar a un prospecto adicional calificado como falso positivo.