



Tecnológico de Monterrey

Tecnológico de Monterrey, Estado de México
Inteligencia Artificial Avanzada para la ciencia de datos

Fecha de entrega: 09/09/2026

M2: momento de retroalimentación
Análisis y Reporte sobre el desempeño del modelo.

A01751729- Andrés Méndez Cortez

Profesor: Jorge Adolfo Ramírez Uresti
Fecha: 14 de septiembre de 2026

Introducción y objetivo

Este reporte documenta el análisis de desempeño de un árbol de decisión ID3 implementado desde cero (sin uso de librerías de machine learning para el entrenamiento), aplicado a un problema de clasificación binaria: predecir si un cliente comprará ("Si") o no comprará ("No") un automóvil, con base en variables categóricas como precio, kilometraje, antigüedad, marca, historial de accidentes y disponibilidad de financiamiento.

El dataset original contenía 200 registros con una distribución de clases desbalanceada (135 casos "Si" y 65 casos "No"). Como parte de este trabajo se amplió el conjunto de datos añadiendo 200 registros sintéticos adicionales, priorizando la clase minoritaria ("No"), con el fin de obtener un conjunto más balanceado y de mayor tamaño que permitiera un diagnóstico más confiable de sesgo, varianza y nivel de ajuste del modelo.

Los objetivos específicos de este reporte son:

- Separar y evaluar el modelo utilizando conjuntos independientes de entrenamiento (train), validación (validation) y prueba (test).
- Diagnosticar el grado de sesgo (bias) del modelo: bajo, medio o alto.
- Diagnosticar el grado de varianza del modelo: bajo, medio o alto.
- Determinar el nivel de ajuste del modelo: underfitting, fitting adecuado (fit) u overfitting.
- Aplicar técnicas de regularización (control de profundidad máxima y tamaño mínimo de partición) para mejorar el desempeño de generalización del modelo, documentando la mejora obtenida.

Dataset y proceso de aumento de datos

Dataset original

El dataset original "dataset_compra_coche.csv" contiene 200 registros y 7 columnas: 6 atributos categóricos (Precio, Kilometraje, Antigüedad, Marca, Historial_Accidentes, Financiamiento_Disponible) y una variable objetivo binaria (Comprar). La distribución original de la variable objetivo era de 135 registros "Si" (67.5%) y 65 registros "No" (32.5%), lo cual representa un desbalance de clases moderado que puede sesgar al árbol hacia la clase mayoritaria y dificultar la evaluación honesta del desempeño, especialmente en un conjunto de prueba pequeño.

Estrategia de aumento de datos

Para aumentar el dataset se generaron 200 registros sintéticos adicionales mediante el uso del modelo de un LLM *Claude Sonet 5.0* (150 de clase "No" y 50 de clase "Si") mediante un proceso generador controlado: se muestrearon aleatoriamente combinaciones válidas de los seis atributos

categoricos y se les asignó una etiqueta de acuerdo con una función de puntaje que pondera la influencia esperada de cada atributo sobre la decisión de compra (por ejemplo, precio alto y antecedentes de accidentes reducen el puntaje; precio bajo, financiamiento disponible y vehículo nuevo lo incrementan), sumando además ruido gaussiano para simular variabilidad e inconsistencias propias de datos reales. Cada combinación se aceptó solamente si su etiqueta resultante coincidía con la clase que se buscaba reforzar ("No" en su mayoría, para corregir el desbalance).

Con este procedimiento, el dataset aumentado ("dataset_compra_coche_aumentado.csv") quedó conformado por 400 registros: 215 de clase "No" (53.75%) y 185 de clase "Si" (46.25%), una distribución considerablemente más balanceada que la original y con el doble de observaciones disponibles para entrenamiento, validación y prueba.




Figura 1. Distribución de la variable objetivo "Comprar" en el dataset original (n=200) frente al dataset aumentado (n=400).

Metodología: separación Train / Validation / Test

Siguiendo el esquema del script original, el dataset aumentado se dividió aleatoriamente (semilla fija random_state=42, para reproducibilidad) en tres conjuntos disjuntos:

- Conjunto de entrenamiento (train): 70% de los datos → 280 registros.
- Conjunto de validación (validation): 15% de los datos → 60 registros.
- Conjunto de prueba (test): 15% de los datos → 60 registros.

El conjunto de entrenamiento se utiliza para construir el árbol ID3 (calculando ganancia de información en cada nodo). El conjunto de validación se emplea exclusivamente para seleccionar los hiperparámetros del modelo (`max_depth` y `min_samples_split`) mediante una búsqueda en malla (grid search), sin tocar en ningún momento el conjunto de prueba. Finalmente, el conjunto de prueba se reserva únicamente para la evaluación final e independiente del modelo seleccionado, generando una estimación no sesgada de su capacidad de generalización.

Conjunto	Nº registros	Clase "No"	Clase "Si"	% del total
Entrenamiento (train)	280	147	133	70%
Validación (validation)	60	36	24	15%
Prueba (test)	60	32	28	15%

Tabla 1. Tamaño y composición de los conjuntos de entrenamiento, validación y prueba sobre el dataset aumentado ($n=400$).

Evaluación del modelo base (sin regularizar)

Como punto de partida se entrenó el árbol ID3 con los hiperparámetros por defecto del código original: `max_depth=None` (sin límite de profundidad) y `min_samples_split=2` (partición mientras existan al menos 2 registros), utilizando únicamente el conjunto de entrenamiento. El árbol resultante alcanzó una profundidad de 6 niveles y 168 nodos, un tamaño considerable para un problema con solo 6 atributos categóricos, lo que indica que el árbol memoriza combinaciones muy específicas de atributos presentes en el conjunto de entrenamiento.

Conjunto	Accuracy
Entrenamiento (train)	0.9464 (94.6%)
Validación (validation)	0.5667 (56.7%)
Prueba (test)	0.6000 (60.0%)

Tabla 2. Accuracy del modelo base (`max_depth=None`, `min_samples_split=2`) en train, validación y test.

La brecha entre el desempeño en entrenamiento (94.6%) y en validación/prueba (56.7% y 60.0%, respectivamente) es muy amplia (~35 puntos porcentuales), lo cual es el síntoma clásico de sobreajuste (overfitting). Adicionalmente, al evaluar en el conjunto de prueba, el modelo base emitió la etiqueta "Unknown" en 11 de 60 registros (18.3%): esto ocurre porque el árbol, al ser tan profundo y específico, generó ramas para combinaciones de atributos que solo existen en el conjunto de entrenamiento, y al encontrarse con combinaciones no vistas en test no pudo realizar ninguna predicción. Este comportamiento es evidencia adicional, e importante, de la incapacidad del modelo para generalizar.




Figura 2. Matrices de confusión sobre el conjunto de prueba: modelo base (izquierda, nótese la columna "Unknown") frente al modelo regularizado (derecha).

Diagnóstico de sesgo, varianza y ajuste (modelo base)

Sesgo (bias): BAJO

El sesgo se refiere al error que comete el modelo incluso sobre los datos que usó para entrenar, es decir, su capacidad para capturar los patrones del conjunto de entrenamiento. El modelo base alcanza 94.6% de accuracy en entrenamiento, lo cual indica un sesgo bajo: el árbol sin restricciones es lo suficientemente flexible y complejo para ajustarse casi perfectamente a los datos de entrenamiento, por lo que el problema de este modelo no es una incapacidad de representación (subajuste), sino todo lo contrario.

Varianza: ALTA

La varianza mide qué tan sensible es el modelo a los datos específicos con los que fue entrenado, es decir, cuánto cambiaría su desempeño con una muestra de entrenamiento distinta. La enorme brecha entre el accuracy de entrenamiento (94.6%) y el de validación/prueba (56.7% / 60.0%) es el indicador directo de varianza alta: el árbol profundo (6 niveles, 168 nodos) construyó reglas hiper-específicas que se ajustan al ruido y a particularidades del conjunto de entrenamiento, en lugar de patrones generales. Esto también se refleja en la curva de aprendizaje (Figura 3, panel izquierdo): la línea de entrenamiento se mantiene siempre muy por encima de la línea de validación, sin mostrar señales de convergencia conforme aumenta el tamaño de la muestra.

Nivel de ajuste: OVERFITTING (sobreajuste)

La combinación de sesgo bajo con varianza alta es la firma característica del sobreajuste. El modelo base memoriza el conjunto de entrenamiento (incluyendo, muy probablemente, ruido y casos particulares) en lugar de aprender reglas generalizables, y como consecuencia su desempeño se degrada considerablemente al enfrentarse a datos nuevos (validación y prueba).

La aparición de predicciones "Unknown" en el conjunto de prueba confirma este diagnóstico: el árbol creció ramas tan específicas para el conjunto de entrenamiento que ni siquiera logra clasificar ciertos registros de prueba con combinaciones de atributos no vistas.




Figura 3. Curvas de aprendizaje (accuracy de train y validación en función del tamaño del conjunto de entrenamiento). Izquierda: modelo base (brecha amplia y persistente = alta varianza / overfitting). Derecha: modelo regularizado (brecha reducida).

Regularización e hiperparámetros para mejorar el modelo

Para corregir el sobreajuste diagnosticado, se aplicó una técnica de regularización estructural propia de los árboles de decisión: limitar la complejidad del árbol mediante el hiperparámetro `max_depth` (profundidad máxima permitida) y aumentar `min_samples_split` (número mínimo de registros necesarios para seguir dividiendo un nodo). Ambos hiperparámetros fueron explorados mediante una búsqueda en malla (grid search) evaluada exclusivamente sobre el conjunto de validación (sin tocar el conjunto de prueba), replicando la metodología del script original:

- `max_depth`: {1, 2, 3, 4, 5, 6, Sin límite}
- `min_samples_split`: {2, 3, 4, 5, 6, 7, 8, 9, 10}

La combinación que obtuvo el mejor accuracy en el conjunto de validación fue `max_depth=3` y `min_samples_split=2`, con un accuracy de validación de 0.65 (65%). La Figura 4 muestra el mapa de calor de accuracy en validación para todas las combinaciones evaluadas: se observa con claridad que `max_depth=3` domina sobre el resto de las profundidades (una franja amarilla horizontal claramente diferenciada), mientras que `min_samples_split` tiene un efecto marginal en este dataset. La Figura 5 (curva de complejidad) confirma este mismo patrón: el accuracy de validación aumenta hasta `max_depth=3` y luego cae abruptamente para profundidades mayores, señal de que a partir de ese punto el árbol comienza a sobreajustarse.




Figura 4. Accuracy en el conjunto de validación para cada combinación de `max_depth` y `min_samples_split` evaluada en la búsqueda en malla.




Figura 5. Curva de complejidad: accuracy en validación en función de `max_depth`, para distintos valores de `min_samples_split`.

Resultados del modelo regularizado

Con los hiperparámetros seleccionados ($\text{max_depth}=3$, $\text{min_samples_split}=2$) se entrenó nuevamente el árbol, primero solo con el conjunto de entrenamiento (para poder comparar de forma justa contra el modelo base en los tres conjuntos) y, posteriormente, siguiendo la metodología del script original, se reentrenó el modelo final combinando entrenamiento + validación, evaluándolo sobre el conjunto de prueba reservado.

Métrica	Modelo base	Modelo regularizado
max_depth	Sin límite	3
min_samples_split	2	2
Profundidad real del árbol	6	3
Nº de nodos	168	25
Accuracy train	0.9464	0.8071
Accuracy validación	0.5667	0.6500
Accuracy test	0.6000	0.7333
Brecha train-test	0.3464	0.0738
Predicciones "Unknown" en test	11 / 60 (18.3%)	0 / 60 (0%)

Tabla 3. Comparación entre el modelo base y el modelo regularizado ($\text{max_depth}=3$, $\text{min_samples_split}=2$).




Figura 6. Comparación de accuracy en train, validación y test entre el modelo base y el modelo regularizado.

Los resultados muestran una mejora clara y consistente tras la regularización:

- El accuracy de prueba (test) subió de 60.0% a 73.3%, una mejora de 13.3 puntos porcentuales, a pesar de que el accuracy de entrenamiento bajó de 94.6% a 80.7%.
- La brecha entre train y test se redujo de 34.6 puntos porcentuales a solamente 7.4 puntos, evidenciando una varianza mucho menor.
- El árbol regularizado es drásticamente más simple (3 niveles y 25 nodos, frente a 6 niveles y 168 nodos), lo que también lo hace más interpretable para un caso de uso de negocio.
- Desaparecen por completo las predicciones "Unknown" en el conjunto de prueba, ya que el árbol generaliza mediante reglas más amplias en lugar de memorizar combinaciones específicas.
- En el reporte de clasificación de prueba, el F1-score de ambas clases sube de 0.64/0.68 (base) a 0.73/0.73 (regularizado), con un balance mucho mejor entre precisión y recall.

Árbol final regularizado

La Figura 7 muestra la estructura completa del árbol final, entrenado con el conjunto de entrenamiento + validación combinados y limitado a max_depth=3. Se observa que el atributo Historial_Accidentes es seleccionado como la raíz del árbol (mayor ganancia de información), seguido de Precio y, en el último nivel permitido, Antigüedad o Financiamiento_Disponible según la rama.

Esta estructura es mucho más compacta e interpretable que la del modelo base, y refleja de forma razonable la intuición de negocio: los clientes sin historial de accidentes y con financiamiento disponible tienden a comprar con mayor frecuencia.




Figura 7. Estructura del árbol de decisión ID3 final, regularizado con $\text{max_depth}=3$ y $\text{min_samples_split}=2$, entrenado con train + validación.

Diagnóstico final tras la regularización

Sesgo (bias): MEDIO

Al limitar la profundidad del árbol a 3 niveles, el accuracy de entrenamiento bajó de 94.6% a 80.7%. Esto representa un incremento del sesgo respecto al modelo base (el modelo ya no puede ajustarse perfectamente a los datos de entrenamiento), pero se mantiene en un nivel medio y no alto: 80.7% de accuracy en entrenamiento sigue siendo un desempeño razonable para un problema con variables categóricas y clases con cierto solapamiento, y no hay indicios de que el modelo sea demasiado simple para el problema (underfitting severo).

Varianza: MEDIA-BAJA

La brecha entre entrenamiento (80.7%) y prueba (73.3%) se redujo a 7.4 puntos porcentuales, y la brecha entre entrenamiento y validación (80.7% vs 65.0%) es de 15.7 puntos, considerablemente menor que en el modelo base. La curva de aprendizaje del modelo regularizado (Figura 3, panel derecho) muestra que las líneas de train y validación están mucho más próximas entre sí y ambas tienden a estabilizarse conforme crece el tamaño de la muestra, lo que indica una varianza notablemente menor. No se alcanza una varianza estrictamente "baja" porque el tamaño del dataset (400 registros) sigue siendo modesto para 6 atributos categóricos con combinaciones múltiples, por lo que aún existe cierta sensibilidad del modelo a la muestra específica de entrenamiento.

Nivel de ajuste: FIT (ajuste adecuado / buen balance)

El modelo regularizado logra un balance mucho más saludable entre sesgo y varianza: ya no memoriza el conjunto de entrenamiento (como sí lo hacía el modelo base), pero tampoco es tan simple como para ignorar patrones relevantes (lo cual sería evidente si, por ejemplo, el accuracy de entrenamiento y de validación fueran ambos muy bajos y similares entre sí, señal de underfitting). El hecho de que el accuracy de prueba (73.3%) sea el más alto de todas las configuraciones evaluadas en la búsqueda de hiperparámetros, junto con una brecha train-test moderada y controlada, respalda la conclusión de que `max_depth=3` y `min_samples_split=2` logran un punto cercano al óptimo de complejidad para este dataset, es decir, un ajuste adecuado (fit) y no un caso de underfitting ni de overfitting.

Conclusiones

El análisis realizado sobre el dataset aumentado (400 registros, con mayor representación de la clase "No") permitió diagnosticar con claridad que la implementación original del árbol ID3, al no tener ningún mecanismo de regularización (`max_depth=None`, `min_samples_split=2`), incurre en un sobreajuste severo: sesgo bajo, varianza alta, y una diferencia de más de 34 puntos porcentuales entre el accuracy de entrenamiento y el de prueba, además de generar predicciones "Unknown" ante combinaciones de atributos no vistas.

Al aplicar una búsqueda de hiperparámetros restringida al conjunto de validación y seleccionar `max_depth=3` junto con `min_samples_split=2`, se logró un modelo considerablemente más simple (de 168 a 25 nodos) que mejoró el accuracy de prueba de 60.0% a 73.3%, redujo la brecha train-test de 34.6 a 7.4 puntos porcentuales, y eliminó por completo las predicciones "Unknown". El diagnóstico final del modelo regularizado corresponde a un sesgo medio, una varianza media-baja y un nivel de ajuste adecuado (fit), lo cual demuestra que la regularización de la profundidad del árbol es una técnica efectiva para combatir el sobreajuste en árboles de decisión ID3 implementados sin librerías, especialmente en datasets de tamaño moderado como el utilizado en este trabajo.

Como trabajo futuro, se sugiere continuar aumentando el tamaño del dataset (idealmente con datos reales adicionales en lugar de sintéticos), explorar técnicas de poda posterior al entrenamiento (post-pruning) y evaluar el desempeño mediante validación cruzada (k-fold) en lugar de una única partición train/validation/test, con el fin de obtener estimaciones aún más robustas del desempeño de generalización del modelo.