



Tecnológico de Monterrey

Tecnológico de Monterrey, Estado de México

Inteligencia Artificial Avanzada para la ciencia de datos

Fecha de entrega: 02/09/2026

M2: momento de retroalimentación

Implementación de un algoritmo de ML sin un framework

A01751729- Andrés Méndez Cortez

Profesor: Jorge Adolfo Ramírez Uresti

Descripción del Algoritmo ID3

El modelo implementado es un Árbol de Decisión basado en el algoritmo clásico ID3. Su funcionamiento se basa en la teoría de la información, utilizando el cálculo de la entropía para medir la impureza de los datos mediante la fórmula $H(S) = -\sum p_i \log_2(p_i)$ y la Ganancia de Información $IG(S, A) = H(S) - H(S|A)$ para seleccionar el atributo que mejor divide el conjunto en cada paso.

El algoritmo funciona correctamente mediante una estructura recursiva que particiona los datos hasta alcanzar uno de tres casos base: pureza total de la clase, agotamiento de atributos, o falta de datos en una rama. El código demuestra su robustez en la fase de inferencia al capturar caminos no explorados y asignarles la etiqueta "Unknown", evitando que el programa colapse ante datos nuevos.




Fig 1.1 Imagen muestra del árbol de decisión categorico generado.

Conjuntos de Datos (Entrenamiento y Prueba)

El modelo fue alimentado con el conjunto dataset_compra_coche.csv, compuesto por variables categóricas (Precio, Kilometraje, Antigüedad, Marca, Historial_Accidentes, Financiamiento_Disponible) para predecir la variable objetivo Comprar.

Se realizó una partición estándar de los datos:

- **Conjunto de Entrenamiento:** 140 registros (70% de los datos) utilizados para construir las ramas y nodos del árbol.
- **Conjunto de Prueba:** 60 registros (30% de los datos) separados para evaluar la capacidad de generalización del modelo ante datos no vistos.

Métricas de Desempeño

Clase / Métrica	Precisión (Precision)	Sensibilidad (Recall)	F1-Score	Soporte (Muestras)
No (No Comprar)	0.77	0.63	0.69	27
Si (Comprar)	0.82	0.85	0.84	33
Unknown (Desconocido)	0.00	0.00	0.00	0
Exactitud Global (Accuracy)	-	-	0.75	60
Promedio Macro	0.53	0.49	0.51	60
Promedio Ponderado	0.80	0.75	0.77	60

Nota: la metrica “Unknown” tiene un soporte de 0 porque no había datos reales etiquetados así, sino que fue la respuesta de contingencia del modelo ante el overfitting.




Fig 2.1 Matriz de confusión del árbol de decisión categórico generado.

De acuerdo con el reporte de clasificación y la matriz de confusión generada por el mismo código, el modelo obtuvo un Accuracy del 75%, acertando en 45 de los 60 casos de prueba.

- **Clase "Si" (Comprar):** Tuvo un desempeño sobresaliente. Logró un Recall de 0.85 (identificó correctamente 28 de 33 casos reales) y un F1-Score de 0.84, demostrando gran sensibilidad para detectar cuándo un coche sí será comprado.
- **Clase "No" (No Comprar):** El rendimiento fue inferior, con un Recall de 0.63. De los 27 casos que realmente eran "No", el modelo acertó 17, se equivocó clasificando 6 como "Si", y no supo qué hacer con 4 de ellos (clasificados como "Unknown").

Análisis y Conclusión

El desempeño general del 75% es bastante bueno para una implementación pura de ID3 sin optimizaciones. Sin embargo, la presencia de 4 predicciones "Unknown" es la prueba de que el algoritmo está sufriendo de **overfitting**. Al dejar que el árbol crezca libremente hasta alcanzar la pureza total en el entrenamiento (140 registros), el modelo memorizó combinaciones muy específicas de atributos. Cuando el conjunto de prueba de 60 registros introdujo combinaciones de características que el árbol jamás había visto, este no supo cómo generalizar y cayó en las ramas vacías.

En conclusión, la lógica matemática del ID3 funciona de manera impecable. Para mejorar la robustez y reducir el overfitting en futuras iteraciones, se recomendaría implementar un mecanismo de prepoda (limitar la profundidad máxima del árbol) o utilizar la clase mayoritaria del nodo padre en lugar de devolver "Unknown" durante la predicción.